ViGoEmotions | Midterm

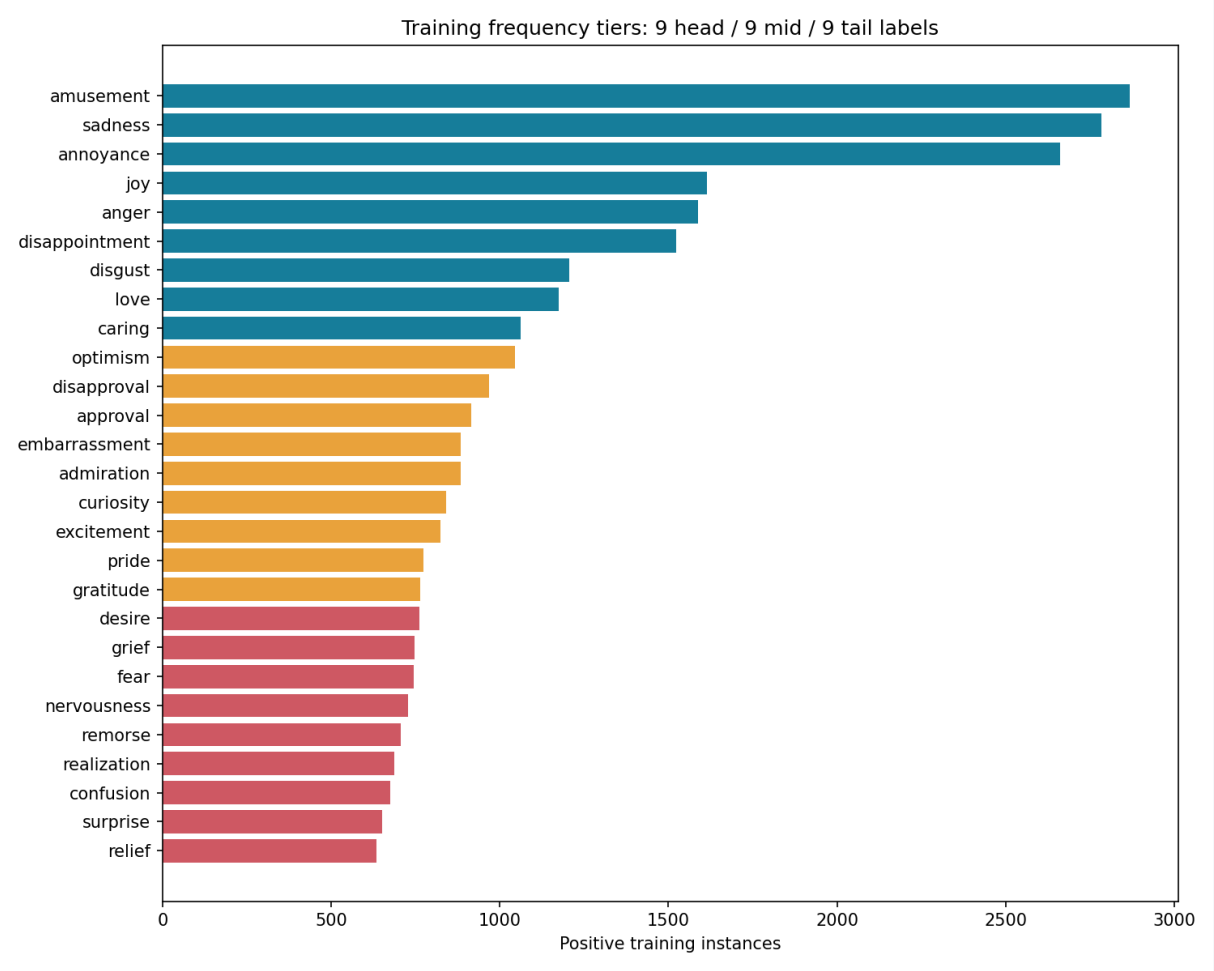
- Nhận diện đa nhãn: một bình luận có thể mang nhiều cảm xúc.
- 27 cảm xúc; neutral là vector 0.
- Bằng chứng hiện có: ba mô hình trên validation.

Dữ liệu & kiểm tra chất lượng

- 20.664 mẫu; split gốc 16.531 / 2.066 / 2.067.
- Loại 1 mẫu train trùng test → train 16.530.
- 306 mẫu mixed-neutral; 1 mẫu lặp nhãn.
- Giữ dữ liệu nguồn riêng; chỉ xuất số liệu và ID.

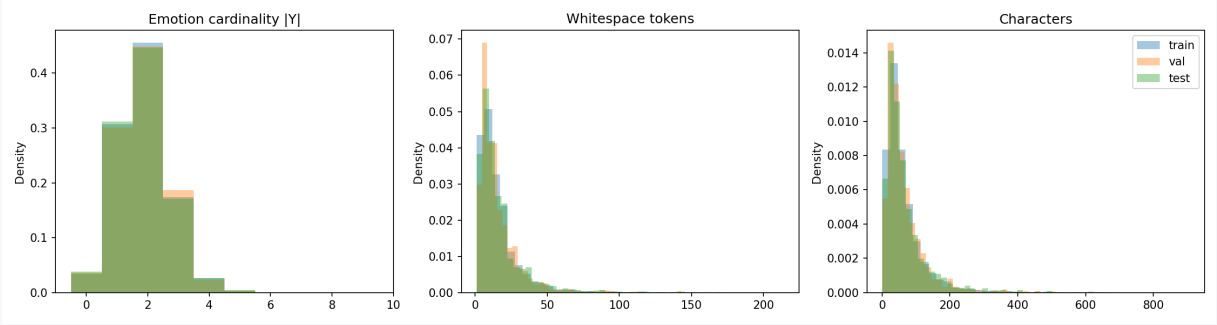
Phân bố 27 nhãn

- 9 nhãn mỗi tier theo tần suất train.
- Amusement cao nhất; relief thấp nhất.
- Chênh lệch max/min: 4.52 lần.
- Nhãn dương thưa hơn vấn đề chênh lệch giữa lớp.



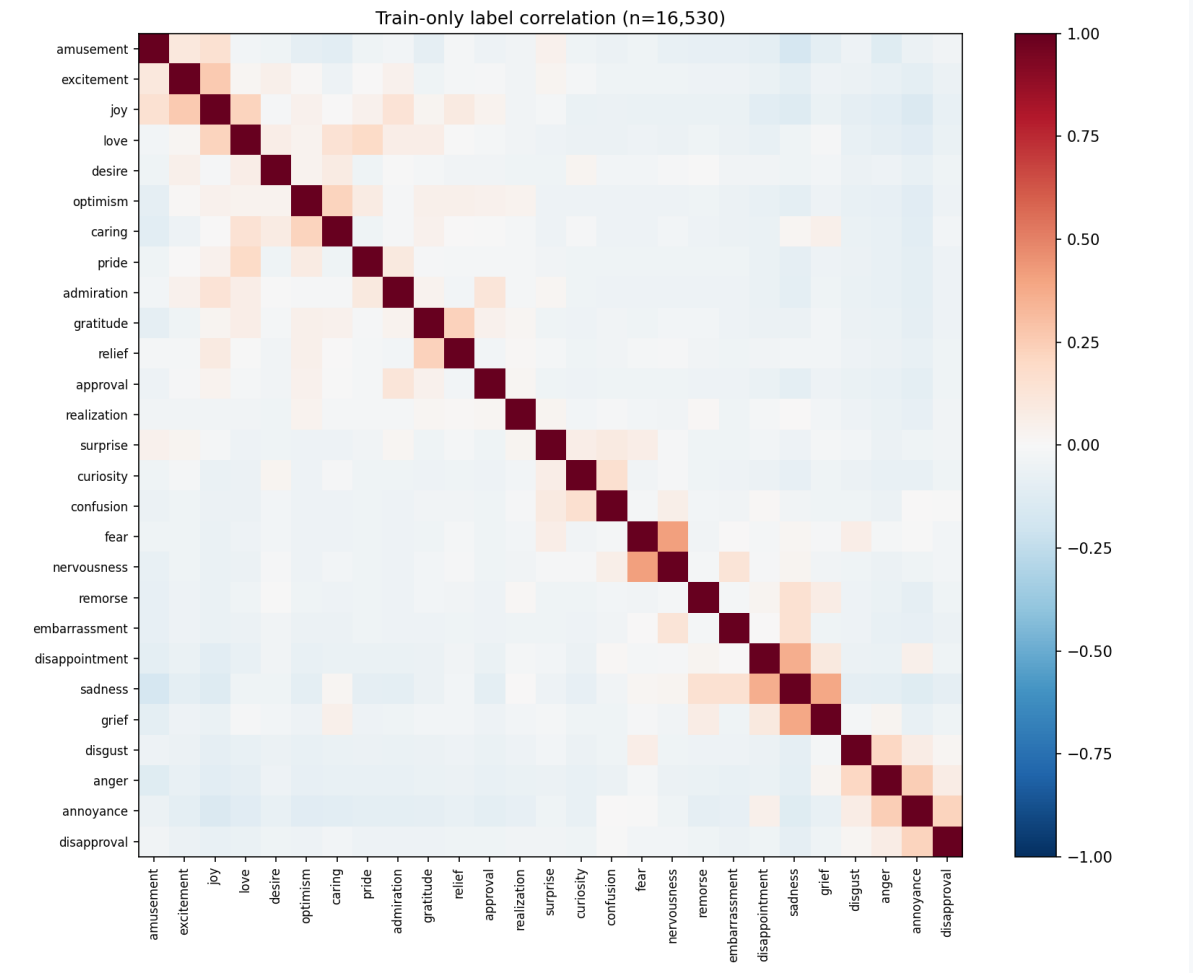
Cardinality & độ dài

- Train: 1.859 cảm xúc/mẫu.
- Cardinality tối đa 5; có neutral-only.
- Median: 11 token khoảng trắng, 47 ký tự.
- Whitespace token ≠ từ tiếng Việt ≠ BPE token.



Các cảm xúc thường đi cùng nhau

- Disappointment–sadness: 904 mẫu train.
- Anger–annoyance: 699.
- Sadness–grief: 620.
- Ma trận chỉ xây trên train; phi không hàm ý nhân quả.



Split & preprocessing

- Giữ split đã cấp; fit vocab/IDF trên train.
- NFC + gom khoảng trắng; giữ dấu và phủ định.
- GRU: whitespace; PhoBERT: VnCoreNLP + BPE.
- Có audit prevalence; chưa chứng minh split gốc được stratified.
- Test giữ cho Final; midterm phân tích validation.

Ba baseline theo đề

- TF-IDF (1–2 grams) + OvR Logistic Regression.
- BiGRU: embedding 128, hidden 128 mỗi hướng, 10 epoch.
- PhoBERT base-v2: revision cố định, 4 epoch.
- Neural: 27 logits + BCE; sigmoid khi dự đoán.
- Chọn checkpoint theo validation Macro-F1 ở 0,5.

Kết quả baseline | validation

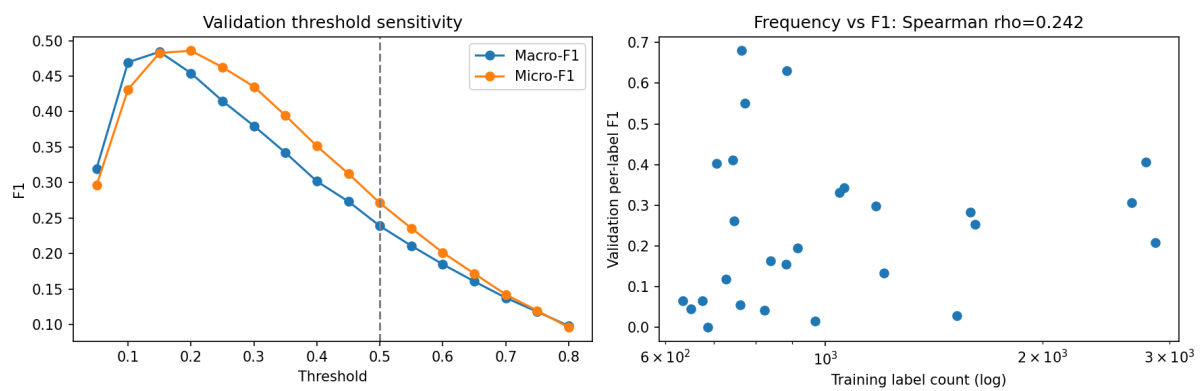
- TF-IDF Macro-F1: 0.2388; Micro-F1: 0.2712.
- Hamming Loss: 0.0606; LRAP: 0.6407.
- 940,626 hệ số + bias; train 2.52 giây CPU.
- BiGRU Macro-F1: 0.4060; PhoBERT: 0.4393.
- Subset accuracy không là metric chính.

Nhãn nào tốt, nhãn nào khó?

- Gratitude F1 0,6797; embarrassment 0,6311; pride 0,5500.
- Realization F1 0; disapproval 0,0160; disappointment 0,0280.
- Tần suất–F1: Spearman rho 0.242, p 0.223.
- Tần suất cao chưa đủ; disappointment là ví dụ.

Ngưỡng 0,5 ảnh hưởng mạnh

- Khảo sát 0,05–0,80 trên validation.
- Ngưỡng 0.15: Macro-F1 0.4844.
- Tăng 24.55 điểm phần trăm.
- Hamming tăng lên 0.0867.
- Chưa chứng minh cải thiện trên test.



Baseline giữ được cặp nhãn?

- Disappointment–sadness: chỉ 2/122 ca validation đúng đủ cặp.
- Joint recall = 1,64% tại ngưỡng 0,5.
- OvR không có cơ chế học cấu trúc nhãn trực tiếp.
- Cần phân biệt phụ thuộc nhãn với vấn đề ngưỡng bỏ sót.

Phong cách & lỗi biên

- TF-IDF Macro-F1: short 0,3310; emoji-heavy 0,1690; teencode 0.1671.
- Emoji bị bỏ bởi word-token TF-IDF; giả thuyết cho FN amusement.
- Câu hỏi giúp đỡ có thể bị FP curiosity.
- Có 20 FN + 20 FP; đã đọc thủ công 10 ca khác nhau.
- Q4 PhoBERT vs GRU: teencode có delta cao nhất: 9.41 điểm phần trăm.

Fine-tune PhoBERT như thế nào?

- Cập nhật toàn bộ pretrained backbone và head 27 logits.
- VnCoreNLP → BPE; tối đa 256 tokens; BCE + sigmoid.
- AdamW: lr 2e-5, batch 16, weight decay 0,01; 4 epoch.
- Chọn checkpoint bằng validation Macro-F1 tại 0,5.
- Fine-tuning đã chạy; tìm hyperparameter là bước bổ sung.

Điều chỉnh learning rate | trạng thái

- Grid: 1e-5 / 2e-5 / 3e-5; chạy lại 2e-5 làm đối chứng.
- Giữ seed, split, batch, số epoch và threshold 0,5.
- Code + notebook 05 đã có; sweep GPU chưa chạy.
- Chưa chọn cấu hình hay kết luận ảnh hưởng learning rate.

Insight hiện có & việc cần kiểm chứng

- PhoBERT hơn BiGRU 3,33 điểm phần trăm Macro-F1 validation.
- Trong các nhóm style, teencode có delta lớn nhất: +9,41 điểm.
- Đây là so sánh baseline, chưa tách riêng tác động của pretraining.
- Đọc đường học, per-label/style delta và ca lỗi của sweep.
- Ghi quan sát thủ công; không coi xuất CSV là đã audit.

RQ Final: một ngưỡng có đủ?

- Chọn neural backbone tốt nhất từ midterm; giữ nguyên trọng số.
- So sánh fixed 0,5 / global tuned / per-label tuned.
- Tune validation → khóa ngưỡng → test đúng một lần.
- Phân tích theo tier/cardinality, profile ngưỡng và val–test gap.

Việc cần chốt trước khi nộp

- Đã kiểm chứng kết quả Colab; lưu riêng checkpoint và vocab.
- Đối chiếu ID-to-label với metadata nguồn; xác nhận split protocol.
- Đọc error analysis neural; bổ sung tên/MSSV/phân công nhóm.
- Gói nộp: PDF, slide, code, README, config, ID, bảng/hình, probabilities.

Nguồn & tái lập

- Đề ViGoEmotions và student-guide: tiêu chí đánh giá.
- Hung et al., EACL 2026: doi.org/10.18653/v1/2026.eacl-long.129.
- PhoBERT: Nguyen & Nguyen, 2020; vinai/phobert-base-v2.
- scikit-learn, Transformers, VnCoreNLP: dẫn nguồn trong báo cáo.
- Seed 42; package versions, checksum, hardware lưu trong run JSON.